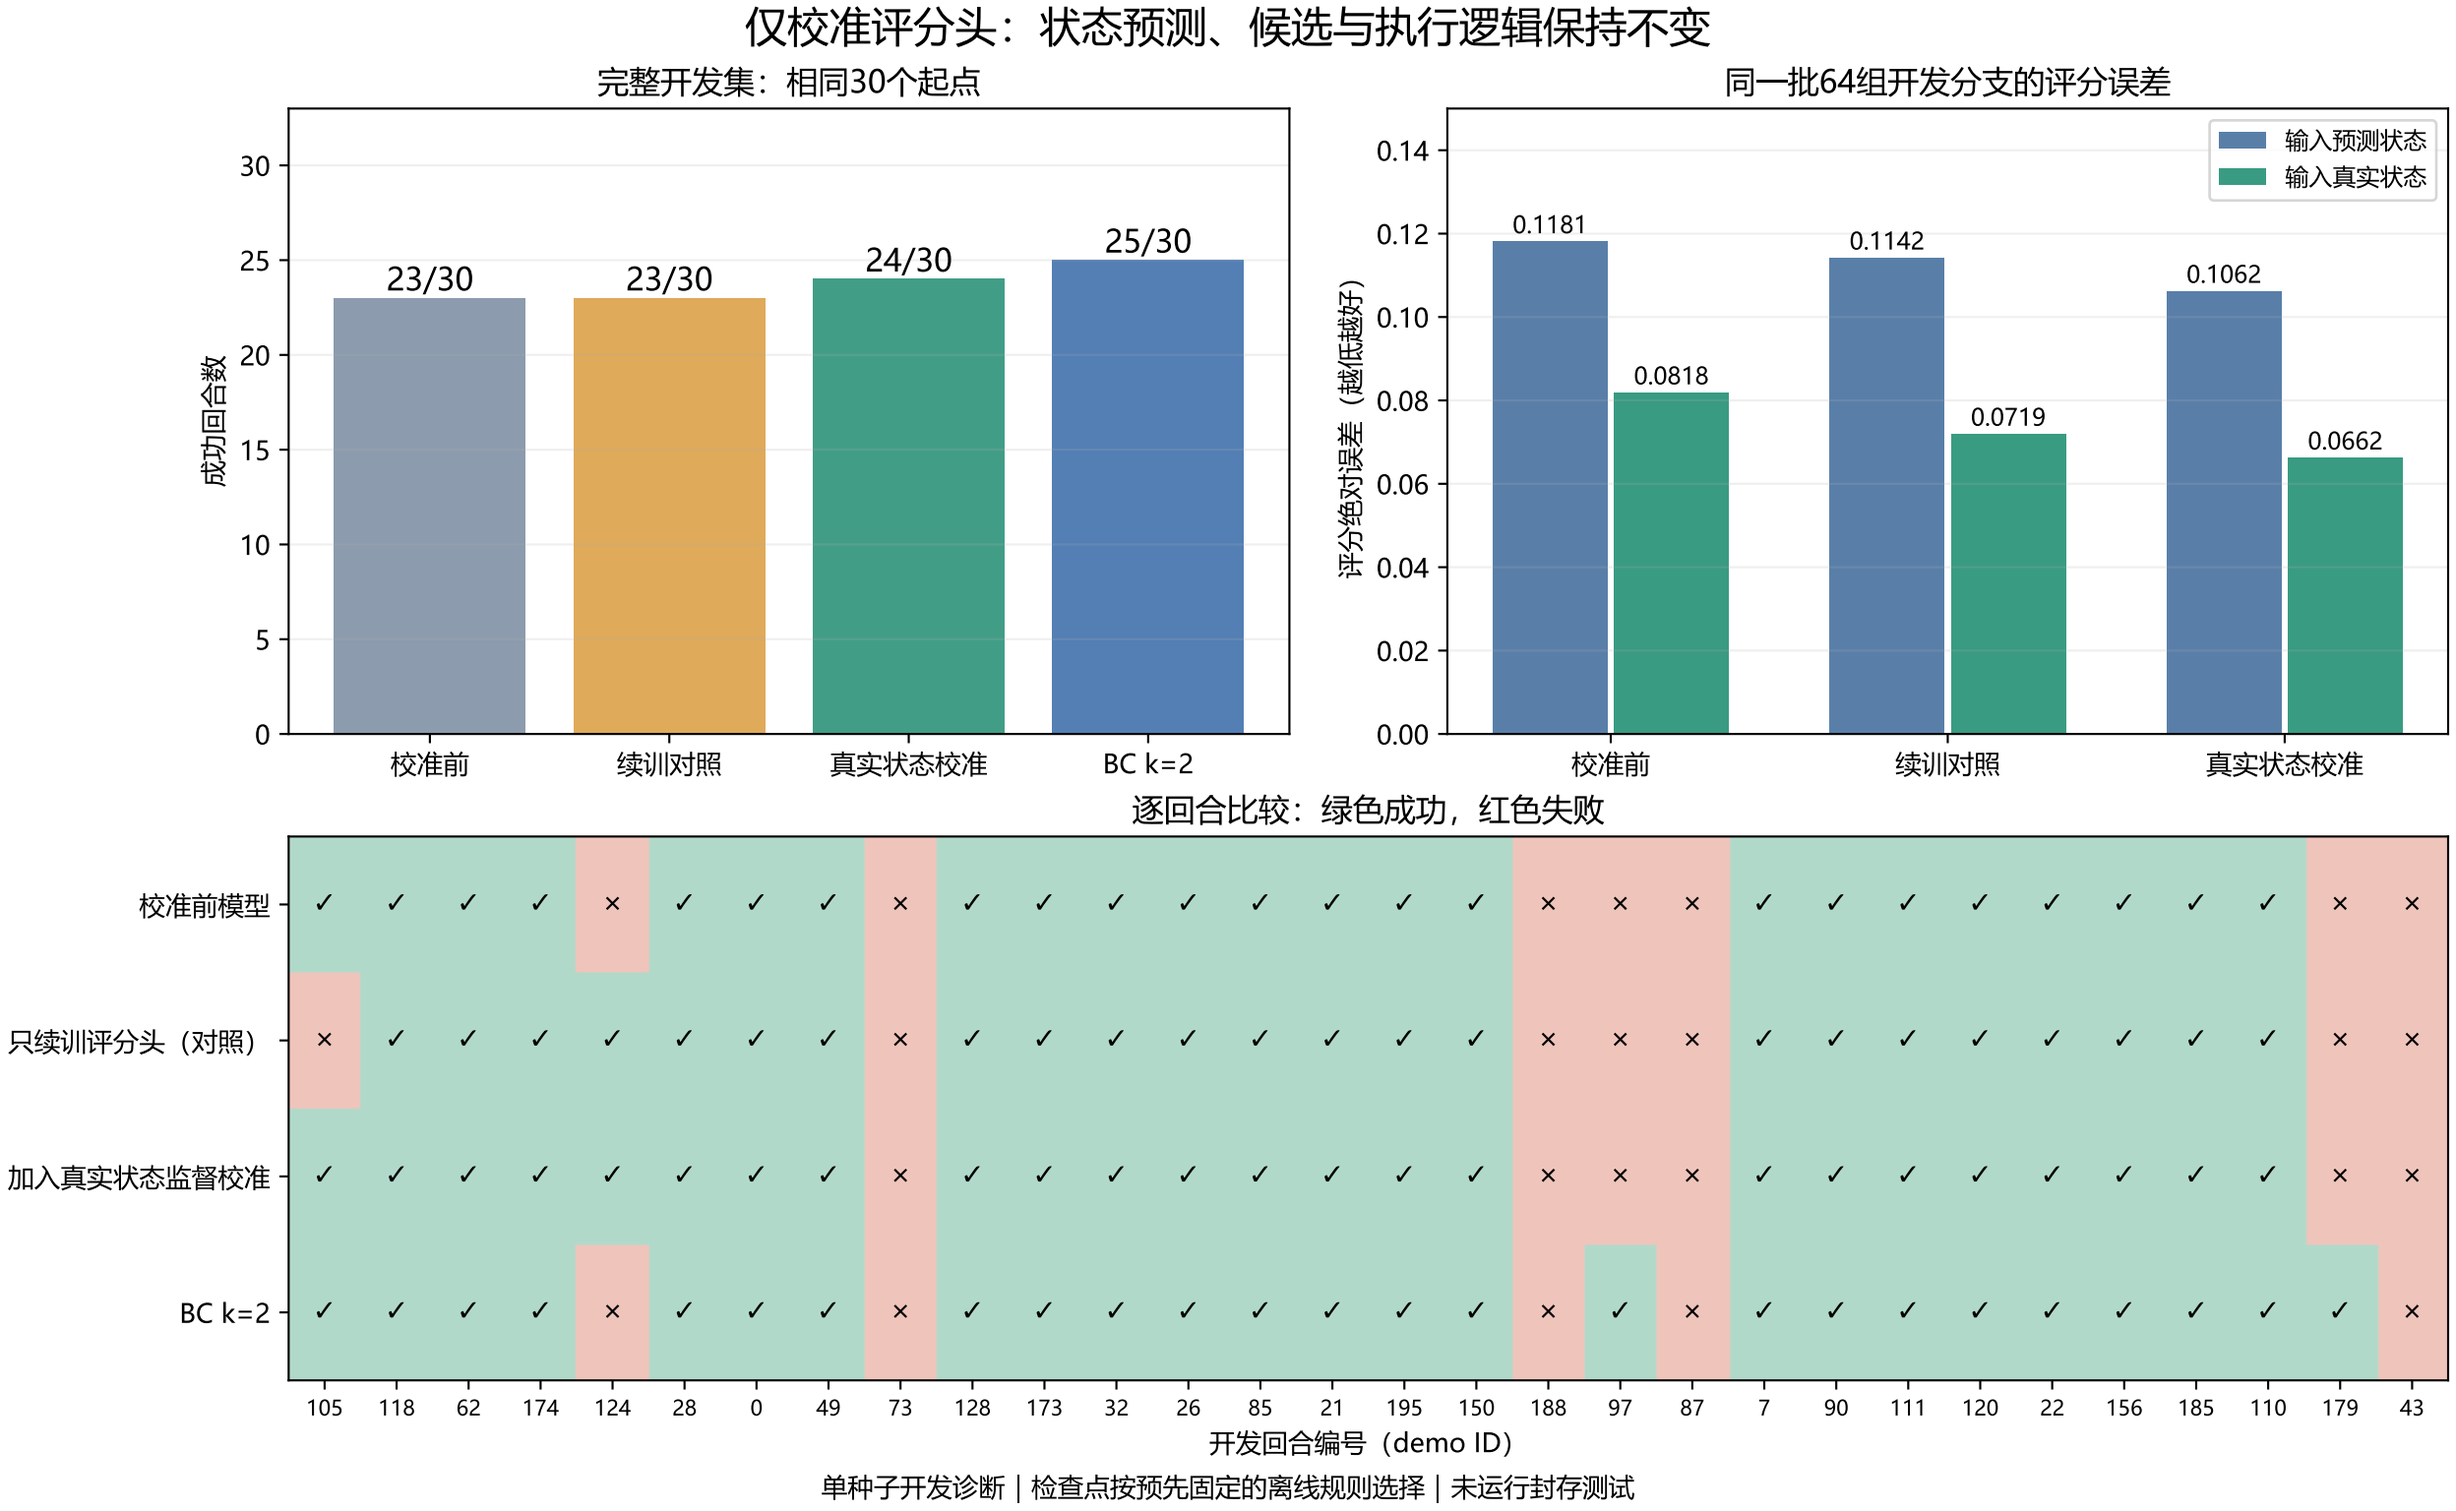

仅校准评分头：状态预测、候选与执行逻辑保持不变
完整开发集：相同30个起点
成功回合数
23/30
23/30
24/30
25/30
校准前
续训对照
真实状态校准
BC k=2
同一批64组开发分支的评分误差
评分绝对误差（越低越好）
输入预测状态
输入真实状态
0.1181
0.0818
0.1142
0.0719
0.1062
0.0662
逐回合比较：绿色成功，红色失败
校准前模型
只续训评分头（对照）
加入真实状态监督校准
BC k=2
105 118 62 174 124 28 0 49 73 128 173 32 26 85 21 195 150 188 97 87 7 90 111 120 22 156 185 110 179 43
开发回合编号（demo ID）
单种子开发诊断｜检查点按预先固定的离线规则选择｜未运行封存测试